

# Prediction conforme

Hazar HAMOUDA - Mohamed MEGDICHE

30 avril 2025

## 1 Un objectif ambitieux ?

L'objectif fondamental de la prédiction conforme est le suivant. Soit  $(X_i, Y_i) \sim P$ , pour  $i = 1, \dots, n$ , une suite de paires i.i.d. (caractéristiques et réponses), issues d'une distribution  $P$  sur  $\mathcal{X} \times \mathcal{Y}$ . Par souci de clarté, on peut supposer que l'espace des caractéristiques est  $\mathcal{X} = \mathbb{R}^d$ , et que l'espace des réponses est  $\mathcal{Y} = \mathbb{R}$ , bien que cela ne soit pas nécessaire en général. Soit  $\alpha \in (0, 1)$  un niveau d'erreur nominal. L'objectif est de construire une *bande de prédiction* :

$$\hat{C}_n : \mathcal{X} \rightarrow \{\text{sous-ensembles de } \mathcal{Y}\}$$

telle que, pour une nouvelle paire  $(X_{n+1}, Y_{n+1}) \sim P$ , on ait :

$$\mathbb{P}(Y_{n+1} \in \hat{C}_n(X_{n+1})) \geq 1 - \alpha, \quad (1)$$

où la probabilité est prise sur l'ensemble des données  $(X_i, Y_i)$  pour  $i = 1, \dots, n+1$ .

D'une part, sans faire d'hypothèse sur  $P$  ni recourir à des approximations asymptotiques, cela peut sembler être un objectif très difficile à atteindre. D'autre part, on peut facilement construire une procédure triviale qui satisfait cette condition ; par exemple :

$$\hat{C}_n(X_{n+1}) = \begin{cases} \mathcal{Y} & \text{avec une probabilité } 1 - \alpha \\ \emptyset & \text{avec une probabilité } \alpha \end{cases}$$

aurait toujours une couverture exacte de  $1 - \alpha$ , c'est-à-dire que l'équation (1) serait satisfaite avec égalité.

La véritable question est donc la suivante (même si elle reste encore quelque peu vague) : peut-on satisfaire (1) avec un échantillon fini, sans faire d'hypothèse sur  $P$ , et de manière *non triviale* ? En particulier, on souhaiterait que notre stratégie s'adapte à la difficulté du problème : plus il est

facile de prédire  $Y_{n+1}$  à partir de  $X_{n+1}$ , plus l'ensemble  $\hat{C}_n(X_{n+1})$  devrait être petit.

## 2 Prédiction Conforme

Théorème : Soit pour  $i = 1, \dots, n$ ,  $(X_i, Y_i) \sim P_{\mathcal{X}Y}$  identiquement distribuées à valeurs dans  $\mathcal{X} \times \mathcal{Y}$ . De plus  $(X_i, Y_i)$  sont finit-galement  $\alpha$ -valeurs dans  $[0; 1]$ , le niveau de confiance  $(n+1)(1-\alpha)$  quantile des scores de calibration  $s_1 = s(X_1, Y_1), \dots, s_n = s(X_n, Y_n)$

## 3 Conclusion

deux fcts qui prennent en entrée les models et ensemble de test ( 1 ere calcule la taille de l'intervalle moyen( pour la regression et la cardinalite pour la classification)(Écarter empiriquement que ds  $1-\alpha$  des cas on a bien ce qui est prédit est ds l'intervalle )) on utilise np.quantile ( il faut utiliser la bonne method(regarder documentation) ) et il faut appliquer prediction conforme sur le model ( o calcule scores sur calibration) interval  $x + \text{quantile} \text{ et l'autre comprend ceux duisoftmax en une equation avec le quantile}$